Implementazione in Open-MP e CUDA dell'algoritmo K-Means

Marco Calamai, Elia Mercatanti

Università degli Studi di Firenze Scuola di Scienze Matematiche, Fisiche e Naturali Corso di Laurea Magistrale in Informatica

Anno Accademico 2019-2020



L'algoritmo K-means

- Inizializzazione centroidi
- Assegnamento dei punti ai clusters
- 4 Aggiornamento dei centroidi
- Riperi 2 e 3 fino a quando gli assegnamenti non cambiano

Implementazione sequenziale K-Means

Strutture utilizzate

- Struct Point per i punti
 - int cluster_id
 - vector (int) dimensions
- Vector(Point) dataset per il dataset
- Vector(Point) centroids per i centroidi scelti random dal dataset comuni a tutte le versioni

Implementazione sequenziale K-Means - struttura

```
sequential kmeans(std::vector<Point> dataset, const int num clusters, std::vector<Point> centroids) {
   std::vector<Point> old_dataset = dataset;
           old_dataset = dataset;
```

Implementazione sequenziale K-Means - assegnamento

Implementazione sequenziale K-Means - aggiornamento

```
id update centroids(const std::vector<Point> &dataset, const int num clusters, std::vector<Point> &centroids)
 for (auto i = 0; i < dataset.size(); i++) {
```

Implementazione sequenziale K-Means - criterio d'arresto

```
bool check_convergence(const std::vector<Point> &dataset, const std::vector<Point> &old_dataset) {
   for (auto i = 0; i < dataset.size(); i++) {
      if (dataset[i].cluster_id != old_dataset[i].cluster_id) {
            return false;
      }
   }
   return true;
}</pre>
```

Implementazione parallela K-Means - benefici

- Fase di assegnamento, operazioni indipendenti
 - Calcolo distanze
 - Determinazione centroide più vicino
- Fase di aggiornamento
 - Eseguendo le somme in modo atomico

Analisi algoritmo K-Means tramite profiler

▼ 94.6% [unknown]`[unknown]	470
▼ 94.2% pc_project`main	468
▼ 93.8% pc_project`sequential_kmeans	466
▼ 89.1% pc_project`points_assignment	443
▶ 85.1% pc_project`calculate_distance	423
2.2% pc_project`std::vector::size	11
< 1% pc_project`std::vector <point, std::allocator<point=""> >::operator[]</point,>	3
2.2% pc_project`update_centroids	11
▶ 1.8% Ø pc_project`std::vector::operator=	9
< 1% pc_project`std::vector <point, std::allocator<point=""> >::operator[]</point,>	2
< 1% pc_project`calculate_distance	1

K-Means in Open-Mp

#pragma omp parallel default(none) shared(dataset, num_clusters, centroids, num_points_clusters)

- Sezione parallela che ingloba i due step del k-means
 - variabili shared: dataset, num clusters, centroids, num points clusters come
 - variabili private: min distance, distance e cluster id

K-Means in Open-Mp - assegnamento

K-Means in Open-Mp - aggiornamento

```
oid update_centroids_openmp(const std::vector<Point> &dataset, const int num_clusters, std::vector<Point> &centroids
  for (auto i = 0; i < dataset.size(); i++) {
```

K-Means in CUDA - struttura

Strutture dati

- Dataset e centroidi array bidimensionali
- Assegnamenti in array

Due kernel per la fase di assegnamento e tre kernel per l'aggiornamento

• fase di sincronizzazione tra ognuno

K-Means in CUDA - assegnamento - compute distances

K-Means in CUDA - assegnamento - points assignment

```
global void points assignment(const double *device distances, short *device assignments)
  int unsigned thread_id = blockDim.x * blockIdx.x + threadIdx.x;
  auto min_distance = INFINITY;
  double distance;
  short cluster id:
  if (thread_id < const_num_points) {
      for (auto i = 0; i < const num clusters; i++) {
          distance = device_distances[thread_id * const_num_clusters + i];
              min distance = distance;
              cluster id = i:
      device_assignments[thread_id] = cluster_id;
```

K-Means in CUDA - aggiornamento - initialize centroids

```
__global__ void initialize_centroids(double *device_centroids) {
    int unsigned col = blockDim.x * blockIdx.x + threadIdx.x;
    int unsigned row = blockDim.y * blockIdx.y + threadIdx.y;

    if (row < const_num_clusters && col < const_num_dimensions) {
        device_centroids[row * const_num_dimensions + col] = 0;
    }
}</pre>
```

K-Means in CUDA - aggiornamento - compute sums

K-Means in CUDA - aggiornamento - update centroids

```
}__global__ void update_centroids(double *device_centroids, const int *device_num_points_clusters) {
   int unsigned col = blockDim.x * blockIdx.X + threadIdx.X;
   int unsigned row = blockDim.y * blockIdx.y + threadIdx.y;

if (row < const_num_clusters && col < const_num_dimensions) {
    device_centroids[row * const_num_dimensions + col] =
        device_centroids[row * const_num_dimensions + col] /
        (double(device_num_points_clusters[row]) / const_num_dimensions);
}
</pre>
```

Test e Risultati

- Test eseguiti su CPU quad core i7 3770K e GPU Nvidia GTX 1080.
- Centroidi iniziali selezionati in modo random dal dataset e riutilizzati per l'esecuzione di ogni versione del K-Means.
- Per ogni versione è stato calcolato il tempo di esecuzione e lo speed-up ottenuto rispetto alla versione sequenziale.
- I test sono stati eseguiti sia su datasets random che su datasets reali.
- Datasets random generati variando numero di punti, numero di dimensioni e numero di cluster da ricercare tra 10, 100 e 1000.

Analisi performance su dataset random

DATASET

	<u> </u>										
		Random 1000x10	Random 1000x100	Random 1000x1000	Random 10000x10	Random 10000x100	Random 10000x1000	Random 100000x10	Random 100000x100	Random 100000x1000	Random 1000000X10
	Sequenziale	0.0995483	0.638251	2.03217	10.2006	52.0753	134.221	162.108	2622.35	14810.8	3873.36
	Open-MP	0.0426349	0.173283	0.547636	3.46449	14.405	38.6007	55.2159	710.503	4081.3	1320.14
10	Speedup Open-MP	2.33	3.68	3.71	2.94	3.62	3.48	2.94	3.69	3.63	2.93
10	CUDA	0.00684048	0.0262636	0.0918535	0.823457	0.988186	2.76661	24.9337	45.3077	289.722	584.845
	Speedup CUDA	14.55	24.30	22.12	12.39	52.70	48.51	6.50	57.88	51.12	6.62
	# ITERAZIONI	22	16	5	228	130	33	363	639	366	861
	Sequenziale	0.390759	2.33382	7.84521	29.5799	150.701	705.307	940.892			
	Open-MP	0.102776	0.595576	1.99878	7.78527	38.7765	180.048	248.872			
100	Speedup Open-MP	3.80	3.92	3.92	3.80	3.89	3.92	3.78			
100	CUDA	0.00773597	0.0408883	0.13143	0.489796	2.22139		14.3992			
	Speedup CUDA	50.51	57.08	59.69	60.39	67.84	70.03	65.34			
	# ITERAZIONI	10	6	2	76	39	18	242		-	-
	Sequenziale	0.786591	7.8893	78.2989	65.8951	733.294	1555.92	3840.99			
	Open-MP	0.198559	1.98681	19.8394	16.776	189.338	401.735	995.712			
1000	Speedup Open-MP	3.96	3.97	3.95	3.93	3.87	3.87	3.86			
1 2000	CUDA	0.0147833	0.134762	1.15328	1.00158	10.5292	21.8604	57.8113			
	Speedup CUDA	53.21	58.54	67.89	65.79	69.64	71.18	66.44			
1	# ITERAZIONI	b	b	2	17	19	4	99			

Analisi performance su dataset reali

DATASET

With K clusters

	IRIS K=3	S1-Set K=15	Birch1-set K=100	Letter K=26	worms_2d K=35	worms_64d K=35
Sequenziale	0.000429641	0.113001	82.724	36.3694	35.5275	579.928
Open-MP	0.000396073	0.0519949	24.2833	10.2238	12.6263	152.624
Speedup Open-MP	1.08	2.17	3.41	3.56	2.81	3.80
CUDA	0.000340643	0.0223294	2.29935	0.774311	3.70815	37.303
Speedup CUDA	1.26	5.06	35.98	46.97	9.58	15.55
# ITERAZIONI	3	14	99	109	106	63

DATASETS DESCRIPTIONS

DATESET	# PUNTI	# DIMENSIONI	#CLUSTERS
IRIS	150	4	3
S1-SET	5000	2	15
BIRCH1-SET	100000	2	100
LETTER	20000	16	26
WORMS_2D	105600	2	35
WORMS 64D	105600	64	35